

Guida allo sviluppo del Progetto per L' Esame di Basi di Dati - Modulo NoSQL A.A. 2025/2026

Svolgere il caso di studio assegnato dal docente il cui dettaglio è disponibile nel file "basi_di_dati_nosql-tracce_progetti_2026_published.pdf" disponibile nella pagina elearning del corso.

- 1 Implementare il caso di studio per ognuno dei DBMS indicati. Il modello dati riportato nel caso di studio è indicativo. Lo studente è libero, previa giusta motivazione, di ampliare tale modello dati aggiungendo Entità, Attributi e/o Relazioni al fine di migliorare il caso di studio.
- 2 **Definire 4 dataset di dimensione crescente** nel seguente modo. Creare un dataset abbastanza grande che "stressi" il più possibile le risorse hardware del computer utilizzato (la dimensione del dataset dipende dalle capacità hardware del computer utilizzato). Il dataset più grande comprenderà il 100% del contenuto informativo considerato. Da questo dataset occorrerà estrapolare un sottoinsieme in maniera da definire un dataset che conterrà circa il 75% del contenuto informativo e così via. Rinominare i 4 dataset 100%, 75%, 50% e 25%.
- 3 Inserire i 4 dataset nei due DBMS considerati (il risultato informativo di una query su un dataset dovrà essere lo stesso in entrambi i DBMS). Il dataset deve essere creato in modo casuale utilizzando un software di generazione dati. A tale scopo si può utilizzare, ad esempio, Mockaroo (<https://www.mockaroo.com>), librerie del linguaggio di programmazione (ad esempio, tramite la Libreria Faker di Python (<https://faker.readthedocs.io/en/master>) o qualsiasi generatore AI (la qualità del dato prodotto è di responsabilità dello studente). I dati generati devono essere veritieri e devono includere un numero abbastanza elevato di relazioni.
- 4 Effettuare un confronto tra i due DBMS con lo stesso dataset definendo 4 query complessità crescenti dal punto di vista del numero di entità coinvolte (l'operazione di correlazione dati tra due entità è l'operazione più onerosa in un database) e dei criteri di selezione. Nei DBMS NoSQL che non hanno il concetto di relazione utilizzare la tecnica dell'annidamento (chiave-valore, dove il valore è una lista di elementi omogenei o eterogenei) o del riadattamento del dataset per ottimizzare la query.
- 5 Utilizzare un linguaggio di programmazione a scelta per interagire con i due DBMS in maniera da automatizzare le operazioni di inserimento (ove necessario) ed esecuzione di query.
- 6 Gli esperimenti dovranno essere automatizzati. Ogni esperimento (esecuzione di una query, per dataset per DBMS) dovrà essere eseguito 31 volte. Poiché molte soluzioni DBMS NoSQL utilizzano meccanismi di memory caching, a parità di dataset, occorrerà considerare il tempo della prima esecuzione della query e il valore medio delle successive 30 esecuzioni espressi in millisecondi (msec) per un totale di 31 esecuzioni. I risultati dovranno essere salvati in un foglio elettronico da elaborare e rappresentare graficamente. Per ogni query dovranno essere creati due istogrammi: uno

con i primi tempi di esecuzione al variare della dimensione del dataset e uno con i tempi di medi di esecuzione al variare della dimensione del dataset per ognuno dei due DBMS considerati. Nel secondo caso occorrerà considerare anche gli intervalli di confidenza al 95% (un tutorial su come graficare gli intervalli di confidenza in un istogramma è disponibile cliccando [qui](#)).

7 Mostrare come i due DBMS si comportano a parità di condizioni hardware/software al variare della dimensione del dataset e della complessità delle query.

8 Gli studenti si dovranno presentare all'esame con un progetto funzionante. Il docente potrà chiedere di eseguire alcune semplici query sui DBMS considerati per verificare il funzionamento del database e la presenza dei dati.

9 Creare un breve report (max 15-20 pagine) che includa le seguenti sezioni:

- Problema affrontato (valutazione max 2 punti)
- Soluzione DBMS considerata (breve descrizione delle principali caratteristiche del database utilizzato) (valutazione max 2 punti)
- Progettazione (contenente descrizione del modello dati utilizzato) (valutazione max 6 punti)
- Implementazione (contenente il codice utilizzato per l'inserimento dei dati e per l'implementazione di ciascuna interrogazione) (valutazione max 6 punti)
- Esperimenti (contenenti tabelle con i tempi di risposta ottenuti e relativi istogrammi) (valutazione max 6 punti)
- Conclusioni (valutazione max 3 punti)

10 Il totale dei punti attribuiti al progetto è 25. A questi, verranno assegnati da 0 a 6 punti aggiuntivi per la presentazione orale del progetto. Il progetto potrà essere sviluppato singolarmente o da un gruppo composto da massimo due studenti comunicato al docente in fase di assegnazione. In questo caso entrambi gli studenti dovranno essere a conoscenza dei dettagli di progettazione e realizzativi del progetto. Nel caso lo studente non dimostri di conoscere il progetto sviluppato, lo stesso verrà annullato, ne verrà assegnato uno nuovo dal docente.

***Il giorno prima dell'esame lo studente deve inviare al docente via email:**

- il report sia in formato docx che pdf;
- il foglio di calcolo comprensivo dei risultati sperimentali e degli istogrammi;
- un collegamento a una cartella OneDrive che include il codice sviluppato e un dump del set di dati più breve (25% del contenuto informativo).

****Il giorno dell'esame gli studenti dovranno discutere il progetto funzionante sul proprio laptop o utilizzando un PC del laboratorio di informatica configurato previa autorizzazione al personale tecnico responsabile del laboratorio dove si svolgerà l'esame.**